计算机视觉大作业报告——用深度学习实现字符识别

组号：13
组员：张政童、方俊杰、李青弈

Github URL：OCR

光学字符识别OCR概述

光字符识别 Optical Character Recognition (OCR)一直是一项计算机视觉的重要应用， 随着人工智能的发展，特别是深度学的流行，深度学习方法开始被广泛应用在 OCR 领域。被谷歌资助的 Tesseract 项目自 2006 年问世以来，一直是业界的领导。而该系统的 Version 4.0 引入了 LSTM 技术，该项目已达到行业标准的水平。

大作业工作内容

1. 积极提交项目进展报告
2. 对项目文档进行理解和认识
3. 对代码不清晰或较难理解部分做出梳理，整理文档
4. 实现并优化图像处理方法，提高识别准确度
5. 换用识别、训练、分类等核心算法，尝试提高识别准确度
6. 识别准确率统计

一、对项目文档进行理解和认识

- 图像预处理
  图像的预处理包括二值化，图像增强，噪声处理，滤波，图像分割等操作。 图像二值化可采用阈值分割技术，擅长处理物体与背景具有较强对比度的图像分割，计算简单，能够用封闭，连同的边界区分出不交叠的区域。但是本次项目所用的图都是灰度图，所以不需要进行灰度处理。 图像增强可以使用基于空间域的增强和基于频率域的增强两种方法。 图像去噪可以使用高斯平滑滤波进行滤波去除噪声，效果比较好，但是此次项目所给图片没有噪音，不用进行此次操作。
- 字符识别
  字母识别：OCR是基于字符结构的方法，对字母识别的成功率较高。字母结构在水平方向上和竖直方向上各有三种类型，笔画也有两大类。根据字符的这些特点，可以对字母进行逐级的分类，形成一颗判定树，每个字符就是一个叶子。这种方法不需要对分割得到的字符进行大小归一化处理，也不需要建立样本库，完全根据字符自身的结构特征进行逼近识别。
  数字识别：先计算欧拉数，再提取凹陷区的特征，最后根据特征组合识别字符。（欧拉数时一种应用广泛的对物体进行识别的特征，定义为连同成分数减去洞数。凹陷区的定义为：如果连接一个图像上任意两点的直线都属于该图像，那么该图像为凸图像。如果连接图像上两点的直线有部分不属于图像，那么称该图像为凹图像，在凹图像中，任意两点间的直线中不属于图像部分所在的区域称为图像的凹陷区）。

二、代码的梳理

我们自己的图像处理结合官方文档给的Demo后，集成在了test.py文件内，代码执行流程如下：

- test.py调用MirrorPlus类：
  MirrorPlus的参数为存储在Pic目录下的文件名，调用mirror1()函数为对图像的处理，产生的中间图片存放在/Code/savedPic里，供后续操作使用

```
m = MirrorPlus(sys.argv[1])
m.mirror1()
```

- 设置config：
  -l代表使用的language，这里采用我们自己训练出来的字符集：d
  --oem代表使用的LSTM OCR engine//Legacy engine，具体数字含义如下：
  - 0 Legacy engine only.
  - 1 Neural nets LSTM engine only.
  - 2 Legacy + LSTM engines.
  - 3 Default, based on what is available.
    这里采用了1
    --psm

```
# Define config parameters.
# '-l eng'  for using the English language
# '--oem 1' for using LSTM OCR Engine
config = ('-l d --oem 1 --psm 3')
```

- 识别图像：
  调用pytesseract库里的image_to_string api，并使用以上config来进行图像识别，将识别结果保留在text中

```
# Run tesseract OCR on image
text = pytesseract.image_to_string(im, config=config)
```

- 保存结果：
  res_path为/Result/result_xx.txt，来保留xx.bmp的识别结果

```
f = open(res_path, 'w')
f.write(text)
f.close()
```

三、图像处理

考虑原图片过小, 我们首先使用了最近邻插值将原本240x128大小的图片转换为1000x500像素, 然后继续了开操作消除毛刺, 继而对镜像反转的图片进行镜像使得文字正置。考虑到背景黑色可能影响

到识别，将整张图片像素值黑白倒置，转换为白底黑字，但又存在三个部分文字与此矛盾，对该三部分再进行黑白导致使得所有文字都为白底黑字。这同时也去除了一些框，可以提高识别率。

- 镜像处理：
  简单地创建一个原图像的副本，使用 **img2[j][i] = img[y - j - 1][i]** 进行像素翻转即可

```
def mirror(self):
    img = self.Interpolation()
    y = img.shape[0]
    x = img.shape[1]
    img2 = copy.deepcopy(img)
    for i in range(x):
        for j in range(y):
            if self.filename != "2.bmp" :
                img2[j][i] = img[y - j - 1][i]
    path = self.filename[0:self.filename.find('.')+1] + "tif"
    path = self.img_save_path + "d.normal.exp" + path
    img2 = self.invertBW(img2)
    cv2.imwrite(path, img2)
```

- 最近邻插值
  由于bmp图像的像素点太少，需要对其进行像素点的扩充,
  原图为128 * 240，临近插值后为500 * 1000

```
 def Interpolation(self):
    img = copy.deepcopy(self.img)
    height,width,channels =img.shape
    emptyImage=np.zeros((500,1000,channels),np.uint8)
    sh=500.0/height#y
    sw=1000.0/width#x
    for i in range(500):
        for j in range(1000):
            x=int(i/sh)
            y=int(j/sw)
            emptyImage[i,j]=img[x,y]
    kernel = np.ones((3,3))
    return cv2.morphologyEx(emptyImage, cv2.MORPH_OPEN, kernel)
```

- 黑白反转
  将图片中的字符统一为白底黑字，黑白反转，对部分字符再次反转，再经过腐蚀操作加粗

```
def invertBW(self, img2):
    img = copy.deepcopy(img2)
    y, x, c = img.shape
    for j in range(y):
        for i in range(x):
            img[j][i] = [255,255,255] - img[j][i]
    return img
```

```
def invertLine(self, img2):
    img = copy.deepcopy(img2)
    y, x, c = img.shape
    kernel = np.ones((3,3))
    # invert up ERROR
    for j in range(0, 31):
        for i in range(360, 640):
            img[j][i] = [255,255,255] - img[j][i]
    # invert mid F8
    for j in range(343, 390):
        for i in range(x):
            img[j][i] = [255,255,255] - img[j][i]
    # invert down G61Q0T
    for j in range(468,500):
        for i in range(738,935):
            img[j][i] = [255,255,255] - img[j][i]
    img = cv2.erode(img, kernel)
    return img
```

- 分割、旋转
  我们还对图片进行了分割与旋转。分割将图片字符行切成条，试图单独训练识别。旋转将一张图片旋转3次生成一共四个方向的图片，试图增加训练图片量。但由于训练方式和进度限制，这些操作最后没有实际集成到图片处理。

四、使用jTessBoxEditor训练，提高准确率

1. 在window环境下安装jTessBoxEditor。
2. 将源图片转换成tif格式，更改名字为[lang].[fontname].exp[num].tif的格式，用于生成box文件。
   - lang：语言
   - fontname：字体
   - num：代表自身的数字
3. 使用jTessBoxEditor将十张图片整合成一张图片：

   jTessBoxEditor->Tools->Merge TIFF->"Select pictures"->Save as "d.normal.exp0.tif"
4. 生成box文件：

```
tesseract d.normal.exp0.tif d.normal.exp0 -l eng1 batch.nochop
makebox
```

5. 用jTessBoxEditor打开d.normal.exp0.tif图片，会自动载入box文件，图形化地来观察识别结果

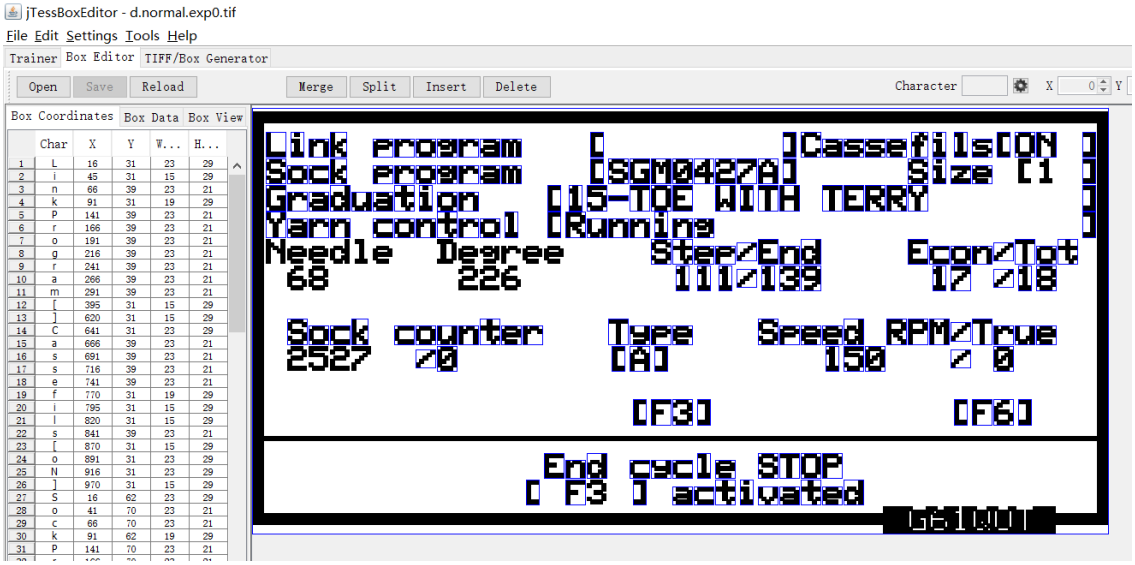

对结果进行纠错：在左边地列表里修改Char、X、Y、W、H应当的值即可

6. 训练流程：

步骤：

- 训练并生成train文件，即以.tr结尾的文件
- 计算字符集合
- 生成中间文件
- 重命名中间文件
- 集成这些中间文件为d.traineddata
- 删除中间文件

bat脚本：

```
echo Run Tesseract for Training..
tesseract  d.normal.exp0.tif d.normal.exp0  nobatch box.train

echo Compute the Character Set..
unicharset_extractor d.normal.exp0.box
mftraining -F font_properties -U unicharset -O d.unicharset
d.normal.exp0.tr

echo Clustering..
cntraining.exe d.normal.exp0.tr

echo Rename Files..
rename normproto d.normproto
rename inttemp d.inttemp
rename pffmtable d.pffmtable
rename shapetable d.shapetable

echo Create Tessdata..
combine_tessdata d.

echo Delete useless file
del
```

```
unicharset,d.unicharset,d.shapetable,d.pffmtable,d.normproto,d.norm
al.exp0.tr,d.inttemp
```

7. 使用自己的训练结果进行图片识别：
   将d.traineddata放入Linux系统里的 ~/usr/share/tesseract/4.00/tessdata里，并将test.py里的config所使用的语言改成d即可。

五、程序使用方法：

- 进入Code目录下，输入以下命令

```
python test.py [picture_name]
```

即可自动载入Pic目录下的图片，并在terminal里输出识别结果

Demo:

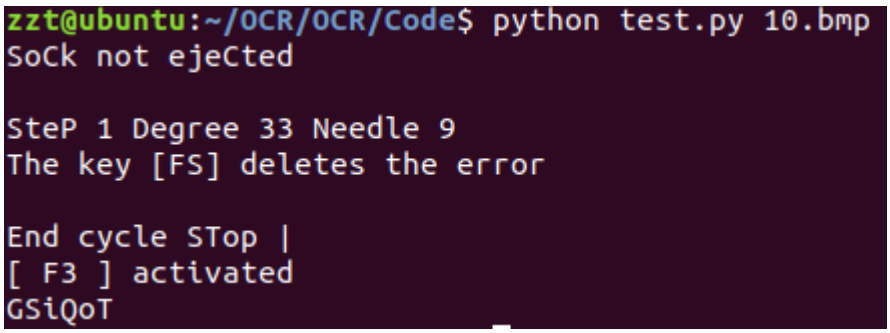

- test.py文件同样会让识别的结果写入Result路径下的result_[picture_name].txt里

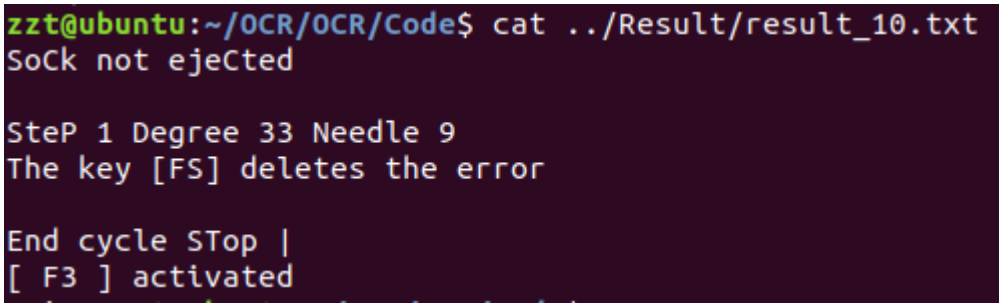

六、识别样例

- 原图片：

- 处理后的图片：

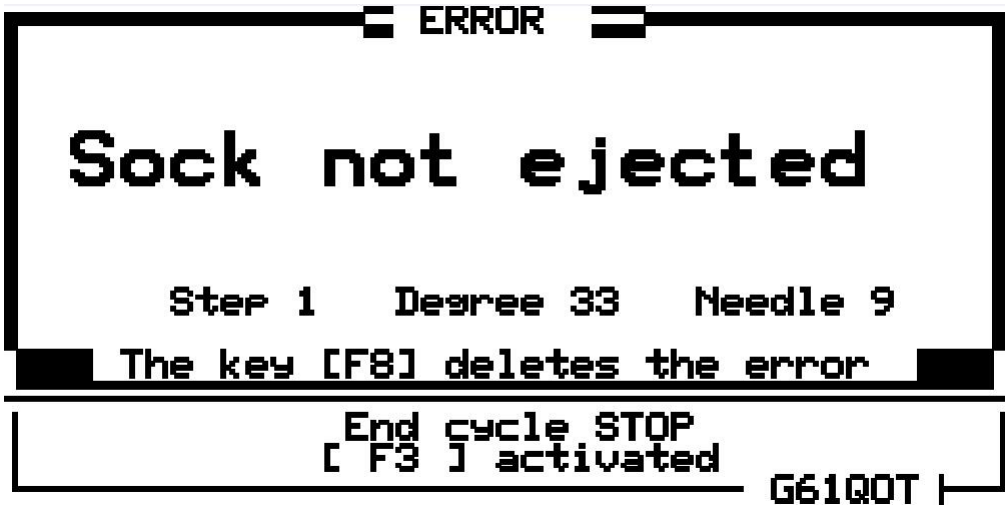

- 识别出的文本：

```
SoCk not ejeCted

SteP 1 Degree 33 Needle 9
The key [FS] deletes the error

End cycle STop |
[ F3 ] activated
GSiQoT
```

七、识别准确率分析

要求：

1. Total: 全部字符数
2. Correctly Recognized: 正确识别字符数
3. Incorrectly Recognized: 错误识别字符数
4. Redundantly Recognized: 图像中并不存在，但被错误识别出的字符数
5. Miss-Recognized: 图像中存在，但没有被识别的字符数

- True Positive: Correctly Recognized
- False Positive: Incorrectly Recognized + Redundantly
- Recognized True Negative: Total Number - Redundantly
- Recognized False Negative: Miss-Recognize
- ***Sensitivity: true positive / (true positive + false negative)***
- ***Specificity: true negative / (true negative + false positive)***

图片编号	**Sensitivity(%)**	**specificity(%)**
1	26.3	100

图片编号	Sensitivity(%)	specificity(%)
2	86.5	97.8
3	96.0	90.9
4	95.7	96.7
5	95.4	96.5
6	95.6	95.9
7	96.0	94.8
8	95.6	95.0
9	95.0	95.4
10	94.6	95.9

八、小组成员分工：

姓名	ID	学号	内容
张政童	zztttt	516030910024	搭建环境、图像处理、训练
方俊杰	FJJLeon	516030910006	图像处理、代码集成
李青弈	liqycarl	516030910008	对文档的梳理、图像处理

项目进展详见
commit history

Reference:

An Overview of the Tesseract OCR Engine
Hybrid Page Layout Analysis via Tab-Stop Detection
Github: tesseract
tesseract识别与训练